UNIVERSITE CLERMONT AUVERGNE

IUT d'Aurillac

Sciences de données

Projet PHR

DEEPFAKE

Encadrant :

Dr Denis MIGDAL

Membres du groupe :

GUYON Axel
POURIZADEH Zahra
DUSSEAUX Mathieu
EVENO Valentin
DABIRE Saanbeterfaa

Année Universitaire : 2025–2026

DEEPFAKE

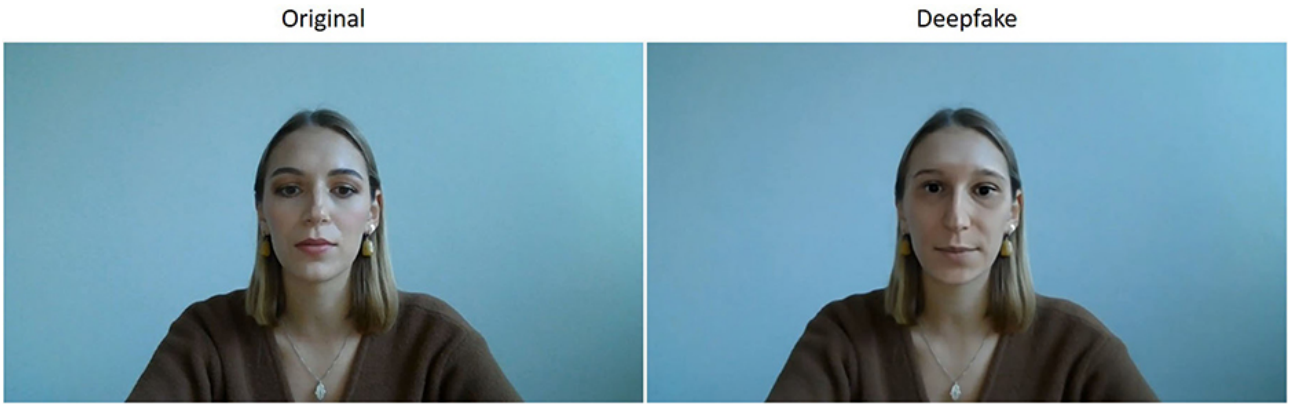

Table des matières

Introduction 1

1 Définition et Fonctionnement des Deepfakes 1

1.1 Qu'est-ce qu'un Deepfake ? 1

1.2 Origine et Évolution Technologique 1

1.3 Technologies Clés Utilisées 1

1.4 Outils de Création de Deepfakes 2

2 Menaces et Usages Malveillants 3

2.1 Désinformation et Manipulation Politique 3

2.2 Fraude et Manipulation Économique 3

2.3 Atteinte aux Individus 3

3 Impacts des Deepfakes 4

3.1 Impacts Sociétaux 4

3.2 Impacts Économiques 4

3.3 Impacts Juridiques 4

4 Moyens de Prévention et de Renforcement 4

4.1 Détection des Deepfakes 4

4.2 Renforcement de l'Authentification 5

4.3 Certification et Protection des Contenus 5

4.4 Sensibilisation et Formation 5

5 Usages Positifs des Deepfakes 5

Références iv

Liste des tableaux

1 Outils et plateformes de deepfake 3

Introduction : L'Ère de la Synthèse Média

Les deepfakes représentent une évolution majeure dans l'application de l'intelligence artificielle (IA) aux médias numériques. Nés des progrès fulgurants du deep learning (apprentissage profond), ces contenus synthétiques, qu'ils soient vidéo, audio ou visuels, sont générés ou modifiés avec un niveau de réalisme sans précédent.

L'émergence des deepfakes est intrinsèquement liée à la capacité croissante des modèles d'IA à comprendre, reproduire et manipuler les données complexes que sont les expressions faciales, les mouvements corporels et les intonations vocales. Cette technologie, souvent qualifiée d'hypertrucage, ouvre un champ d'opportunités considérable dans des domaines tels que le divertissement, l'éducation ou la création artistique. Cependant, elle introduit également une menace significative en matière de cybersécurité, de désinformation et d'atteinte à la confiance.

Ce cours vise à analyser en profondeur le fonctionnement des deepfakes, les technologies sous-jacentes, les menaces qu'ils posent, leurs impacts sociétaux et les moyens de prévention et de lutte mis en œuvre.

1 Définition et Fonctionnement des Deepfakes

1.1 Qu'est-ce qu'un Deepfake ?

Le terme deepfake est un néologisme issu de la contraction de « deep learning » (apprentissage profond) et de « fake » (faux). Il désigne un contenu numérique (vidéo, image ou audio) généré ou modifié par des algorithmes d'intelligence artificielle pour faire dire ou faire faire à une personne des choses qu'elle n'a jamais faites.

Contrairement aux montages vidéo traditionnels, les deepfakes s'appuient sur des modèles d'apprentissage profond pour créer des artefacts numériques qui imitent de manière extrêmement réaliste les caractéristiques humaines. Leur réalisme élevé rend leur détection de plus en plus difficile pour l'œil humain.

1.2 Origine et Évolution Technologique

Les bases technologiques des deepfakes ont été posées autour de avec l'invention des Réseaux Antagonistes Génératifs (GANs) par Ian Goodfellow. Le terme lui-même est apparu publiquement en sur la plateforme Reddit, initialement associé à la diffusion de vidéos falsifiées impliquant des célébrités.

1.3 Technologies Clés Utilisées

La création de deepfakes repose sur la combinaison de plusieurs technologies avancées de deep learning :

A. Réseaux Antagonistes Génératifs (GANs)

Les GANs constituent le cœur de la plupart des systèmes de deepfake. Ils fonctionnent sur

un principe de jeu à somme nulle entre deux réseaux de neurones :

- **Le Générateur (G)** : Il crée du contenu synthétique (images, vidéos, audio) à partir de données d'entrée
- **Le Discriminateur (D)** : Il évalue l'authenticité du contenu produit par le Générateur. Son rôle est de distinguer les contenus réels des faux.

Les deux modèles s'entraînent mutuellement de manière itérative. Le Générateur cherche à tromper le Discriminateur, tandis que le Discriminateur s'améliore pour détecter les faux. Ce processus adversarial pousse le Générateur à produire des deepfakes d'une qualité de plus en plus réaliste.

B. Auto-encodeurs (Autoencoders)

Les auto-encodeurs sont particulièrement utilisés pour le face-swapping (échange de visage). Ils se composent de deux parties :

- **L'Encodeur** : Il prend une image du visage d'une personne (la source) et la compresse en une représentation de données de faible dimension appelée espace latent. Cet espace latent capture les caractéristiques essentielles du visage et de l'expression.
- **Le Décodeur :** Il prend la représentation de l'espace latent et la décompresse pour reconstruire l'image du visage.

Pour créer un deepfake, deux auto-encodeurs sont entraînés sur les visages de deux personnes différentes (A et B), mais ils partagent le même Encodeur. Pour échanger le visage de A sur le corps de B, l'Encodeur extrait l'espace latent du visage de A, et le Décodeur entraîné sur le visage de B est utilisé pour reconstruire un nouveau visage B avec les expressions et les mouvements de A.

C. Autres Technologies

- **Réseaux de Neurones Convolutifs (CNN)** : Utilisés pour l'analyse d'images et la reconnaissance faciale, ils permettent de reproduire avec précision les traits et expressions du visage.
- **Réseaux de Neurones Récurrents (RNN)** : Essentiels pour le traitement des séquences temporelles, ils sont utilisés pour assurer la synchronisation labiale et la cohérence des mouvements dans les vidéos.
- **Traitement du Langage Naturel (NLP)** : Indispensable pour les deepfakes audio, il permet d'imiter le style, le timbre et la voix d'un individu.
- **Matériel de Haute Performance (GPU/Cloud)** : Nécessaire pour l'entraînement et la génération de contenus de haute qualité en raison de la complexité des calculs

1.4 Outils de Création de Deepfakes

La création de deepfakes est devenue accessible grâce à une variété d'outils, allant des plateformes professionnelles aux logiciels open source :

Catégorie	Outil / Plateforme	Description et Usage Principal
Logiciel Open Source	**DeepFaceLab**	Logiciel très puissant nécessitant un GPU performant, principalement utilisé pour le face-swapping vidéo.
Logiciel Open Source	**Faceswap**	Alternative open source orientée interface utilisateur, pour l'échange de visages dans des images et vidéos.
Plateformes Professionnelles	**HeyGen**	Plateforme en ligne pour la création de vidéos d'avatars IA à partir de texte, images ou audio.
Plateformes Professionnelles	**Resemble AI**	Spécialisé dans le clonage vocal et la génération de voix synthétiques réalistes.
Outils de Synthèse Média	**Kapwing / JoggAI**	Outils en ligne pour le deepfake éthique et l'édition vidéo.
Outils de Synthèse Média	**RunwayML / Pika**	Générateurs vidéo IA (texte-vers-vidéo) pour créer des scènes ou personnages synthétiques.

Table 1 – Outils et plateformes de deepfake

2 Menaces et Usages Malveillants

Les deepfakes représentent une menace croissante en cybersécurité en raison de leur réalisme et de leur facilité de diffusion.

2.1 Désinformation et Manipulation Politique

Les deepfakes sont un outil puissant pour la désinformation. Ils permettent de simuler des déclarations ou des actions de personnalités publiques, fragilisant la confiance envers les médias, les institutions et les processus démocratiques. Un deepfake convaincant peut être diffusé rapidement, créant un climat de doute généralisé face à tout contenu audiovisuel.

2.2 Fraude et Manipulation Économique

Dans le domaine de la fraude, les deepfakes sont de plus en plus utilisés dans les attaques d'ingénierie sociale :

- **Fraude au Président (CEO Fraud)** : Un deepfake audio peut imiter la voix d'un dirigeant pour ordonner un virement frauduleux à un employé.
- **Escroqueries par Imitation Vocale** : L'utilisation de voix clonées pour contourner les systèmes de vérification biométrique ou pour extorquer des informations sensibles.

2.3 Atteinte aux Individus

L'un des usages les plus graves concerne la création de contenus falsifiés à caractère diffamatoire ou pornographique non consenti (non-consensual deepfake pornography). Ces actes

constituent une atteinte sévère à la réputation, causent une détresse psychologique et peuvent mener au cyberharcèlement et au chantage. Les femmes sont particulièrement ciblées par ce type de contenu.

3 Impacts des Deepfakes

3.1 Impacts Sociétaux

L'impact sociétal majeur des deepfakes est la perte de confiance dans l'authenticité des informations. Lorsque l'on ne peut plus faire confiance à ce que l'on voit ou entend, cela érode la base même de la communication et du débat public. Cette érosion contribue à la polarisation et à la difficulté de distinguer la vérité du mensonge.

3.2 Impacts Économiques

Les entreprises peuvent subir des pertes financières importantes dues à la fraude, mais aussi une atteinte irréparable à leur image de marque et à leur réputation si elles sont la cible de deepfakes malveillants. Les secteurs bancaire et assurantiel sont particulièrement exposés aux risques juridiques et financiers liés à la vérification d'identité et à la preuve numérique.

3.3 Impacts Juridiques

Le cadre juridique peine à suivre l'évolution rapide de cette technologie. Les deepfakes soulèvent des questions complexes concernant :

- **Droit à l'image et à la voix :** Qui possède les droits sur l'image synthétisée d'une personne ?
- **Preuve numérique :** Comment déterminer l'authenticité d'une preuve vidéo ou audio dans un procès ?
- **Responsabilité légale :** Qui est responsable en cas de dommage causé par un deepfake (le créateur, la plateforme de diffusion, l'outil) ?

4 Moyens de Prévention et de Renforcement

La lutte contre les deepfakes nécessite une approche combinée, technologique, humaine et juridique.

4.1 Détection des Deepfakes

Des outils basés sur l'IA sont développés pour identifier les anomalies subtiles que les deepfakes laissent derrière eux, telles que :

- **Incohérences visuelles :** Clignements des yeux anormaux, mouvements de tête non naturels, ou artefacts de compression.
- **Incohérences audio :** Variations dans le bruit de fond ou le spectre vocal.
- **Analyse des métadonnées :** Recherche de traces numériques laissées par les outils de génération.

Ces solutions de détection doivent être continuellement mises à jour pour contrer les progrès des techniques de génération.

4.2 Renforcement de l'Authentification

Pour contrer la fraude par imitation, le renforcement de l'authentification est crucial :

— **Authentification Multi-Facteurs (MFA)** : L'ajout de facteurs d'authentification autres que la biométrie faciale ou vocale seule.

— **Vérifications Croisées** : Utilisation de vérifications dynamiques et de défis pour s'assurer que la personne est vivante et présente (par exemple, demander d'effectuer une action spécifique).

4.3 Certification et Protection des Contenus

Des mécanismes de protection des contenus originaux sont mis en place :

— **Filigranes numériques (Watermarking) :** Ajout de marques invisibles aux médias pour prouver leur origine et leur authenticité.

— **Blockchain pour la traçabilité :** Utilisation de la technologie blockchain pour enregistrer l'historique d'un média et garantir qu'il n'a pas été altéré.

— **Gestion des droits numériques (DRM) :** Chiffrement et contrôle d'accès pour protéger les contenus sensibles.

4.4 Sensibilisation et Formation

La formation du public et des professionnels est un élément clé. Il est essentiel de former les employés et les utilisateurs à reconnaître les signes d'un deepfake et à adopter une attitude critique face aux contenus audiovisuels, en particulier ceux qui suscitent une forte réaction émotionnelle.

5 Usages Positifs des Deepfakes

Malgré les risques, la technologie des deepfakes possède des applications bénéfiques :

— **Cinéma et doublage multilingue :** Permet de doubler des acteurs dans différentes langues en synchronisant parfaitement leurs lèvres avec la nouvelle piste audio, rendant le doublage plus réaliste.

— **Apprentissage et éducation :** Création d'avatars interactifs pour l'apprentissage des langues ou la formation professionnelle, offrant des expériences immersives et personnalisées.

— **Création artistique et musique :** Utilisation de l'IA pour générer des œuvres d'art, des compositions musicales ou des effets visuels innovants.

— **Restauration historique :** Amélioration de la qualité de vieilles vidéos ou photos, ou création de reconstitutions historiques plus vivantes.

Conclusion

Les deepfakes constituent une technologie à double usage (dual-use technology). Ils ouvrent de nouvelles perspectives créatives et éducatives, tout en posant un défi majeur à la cybersécurité et à la confiance sociétale.

Pour exploiter les bénéfices de cette technologie tout en limitant ses impacts négatifs, une approche globale est indispensable. Celle-ci doit combiner l'innovation dans les outils de détection, le renforcement des systèmes d'authentification, l'établissement d'un cadre juridique adapté et une sensibilisation accrue du public. L'avenir de l'information dépendra de notre capacité à gérer cette nouvelle réalité médiatique.

Références

1. SentinelOne. Deepfakes : définition, types et exemples clés.
2. IUT Aurillac. Oral Présentation PHR – Deepfake.
3. Jedha. Generative Adversarial Networks (GAN) : principes et usages.
4. The AI Summer. Deepfakes : Face synthesis with GANs and Autoencoders.
5. Nexa. Qu'est-ce que les Generative Adversarial Networks (GAN).
6. LinkedIn. #28 How are deepfakes made using Variational Autoencoders.
7. GitHub. DeepFaceLab is the leading software for creating deepfakes.
8. HeyGen. Free AI Video Generator : Create Stunning Videos with AI.
9. APUS. What Is Deepfake Technology ? Understanding Its Broad Impact.
10. Unit21. Deepfake : How the Technology Works & How to Prevent.